El Dinero compra la felicidad? analizando la asociación entre el ingreso por hogar y las tasas de sucidio

Juan Felipe Moreno Rodriguez
Estadístico

Capítulo 1: Resumen

La relaación entre los ingresos altos y las altas tasas de suicidios ha sido abiertamente documentado,

En Liang y Su, 2022, se compara el ingreso mediano de los condados de Estados Unidos con el ingreso medio por hogar, junto con un análisis del número promedio de suicidios y su relación con la tasa de suicidios por condado. Además, mediante modelos de efectos mixtos, se establece una asociación entre estas variables y otros factores de confusión.

A diferencia de ese enfoque, esta propuesta realiza una estimación alternativa que considera datos agrupados por clusters en el tiempo, tratando las observaciones como agrupadas en lugar de estimar efectos aleatorios.

El artículo de Hanley et al., 2003 se presenta como una guía didáctica destinada a facilitar la comprensión y aplicación de las **Ecuaciones de Estimación Generalizadas (GEE)** entre epidemiólogos y otros científicos sin formación estadística avanzada. Utilizando un ejemplo concreto, el trabajo ilustra cómo las GEE permiten analizar correctamente datos **correlacionados**, como aquellos provenientes de individuos agrupados en un mismo hogar, evitando el error común de tratarlos como observaciones independientes.

En estudios con datos **longitudinales** o **agrupados en clústers** (hogares, escuelas, centros médicos, etc.), es esencial ajustar los análisis estadísticos para reflejar adecuadamente la dependencia entre observaciones. Ignorar esta correlación puede llevar a errores estándar subestimados y, por ende, a conclusiones engañosas.

Como caso de estudio, se utiliza una base de datos compuesta por 144 niños de 54 hogares en México, con información sobre altura estandarizada (z-score), sexo y nivel socioeconómico. El análisis demuestra que ignorar la dependencia entre hermanos dentro del mismo hogar *sobrestima la precisión* de las estimaciones.

Capítulo 2: Materiales y Métodos

Método GEE

Las GEE se basan en un sistema de ecuaciones de estimación que combinan observaciones correlacionadas utilizando **pesos derivados de una estructura de correlación asumida**. El procedimiento se desarrolla en los siguientes pasos:

1. Estimación inicial del parámetro de interés (por ejemplo, una media o una proporción).
2. Cálculo de residuos y estimación de la correlación intra-clúster.
3. Ajuste de los pesos ω_i de las observaciones según la correlación estimada.
4. Repetición del proceso hasta alcanzar la convergencia de los parámetros.

Este enfoque permite extender los *Modelos Lineales Generalizados (GLMs)* a contextos donde existe dependencia entre las observaciones, sin necesidad de especificar completamente la distribución conjunta dentro de cada clúster.

Estimación por GEE

Para ilustrar la estimación de la media poblacional con GEE, se consideran distintos escenarios en función del tamaño del hogar:

$$y_1 = y_{\text{singleton}} \quad \text{(hogar con un hijo)}$$
$$y_2 = y_{\text{sib1}}, \quad y_3 = y_{\text{sib2}} \quad \text{(hogar con dos o más hijos)}$$

Cada observación y_i cumple con la ecuación de estimación:

$$y_i - \hat{\mu} = 0$$

Al combinar estas ecuaciones usando pesos w_i, se obtiene:

$$\sum_{i=1}^{3} w_i(y_i - \hat{\mu}) = 0 \quad \Rightarrow \quad \hat{\mu} = \frac{\sum w_i y_i}{\sum w_i}$$

Dado que la correlación intra-clúster R es desconocida, el proceso se vuelve iterativo:

1. Se parte de un valor inicial $R = 0$ para calcular $\hat{\mu}$.
2. Se estima R a partir de los residuos intra-clúster.
3. Se recalculan los pesos y se actualiza $\hat{\mu}$.
4. El ciclo se repite hasta que las estimaciones se estabilicen.

Este enfoque puede extenderse a modelos de regresión mediante versiones *ponderadas de mínimos cuadrados*, lo que permite estimar coeficientes ajustados respetando la estructura de dependencia de los datos.

Errores Estándar: ¿Basados en el Modelo o Empíricos?

Una de las contribuciones más destacadas del artículo es la comparación entre dos enfoques para estimar la **desviación estándar** (o error estándar, SE) de los parámetros obtenidos mediante GEE: el basado en el modelo y el empírico o robusto.

Supongamos ahora que se desea estimar una **proporción poblacional**, $\hat{p} = 0{,}42$, en lugar de una media. El método GEE puede aplicarse de forma análoga en el caso de variables binarias, permitiendo obtener estimaciones consistentes y errores estándar válidos incluso en presencia de correlación intra-clúster.

Error Estándar Basado en el Modelo

Este error se calcula bajo una **estructura de correlación asumida**, por ejemplo, una estructura intercambiable. El error estándar se expresa como:

$$SE_{\text{modelo}}(p) = \sqrt{\frac{p(1-p)}{\sum w}} = \sqrt{\frac{0{,}42 \times 0{,}58}{3{,}39}} \approx 0{,}27$$

Error Estándar Empírico (Robusto)

Se calcula a partir de la **variabilidad real** observada entre los clústeres. Por ejemplo, si en dos hogares se observan proporciones de $p_1 = 0/3 = 0$ y $p_2 = 4/5 = 0{,}8$, entonces:

$$SE_{\text{empírico}}(p) = \sqrt{\frac{1{,}59^2(0 - 0{,}42)^2 + 1{,}80^2(0{,}8 - 0{,}42)^2}{3{,}39^2}} \approx 0{,}28$$

Comparación y Consideraciones Prácticas

- En muestras adecuadas, el error empírico suele ser más confiable.
- Si ambos métodos arrojan resultados similares, se considera que la estructura de correlación asumida es apropiada.
- En muestras pequeñas, se recomienda el uso de la distribución t en lugar de z para inferencias más precisas.
- Si el tamaño del clúster se relaciona con el desenlace (clústeres no ignorables), es preferible emplear técnicas de remuestreo intra-clúster combinadas con modelos GLM estándar.

Capítulo 3: Resultados

Los datos fueron recolectados de dos fuentes diferentes. La primera fue de los Centros para el Control y la Prevención de Enfermedades (CDC). El CDC Wonder es un servicio público operado por el CDC, una agencia del gobierno federal de los Estados Unidos. Por medio del CDC Wonder, obtuvimos eventos de suicidio por condado y conteos de género y raza desde 2010 hasta 2019 Centers for Disease Control and Prevention, 2024. Mientras tanto, del Departamento del Censo de EE. UU., obtuvimos conjuntos de datos con conteos de nivel educativo, relacionados en particular con el título de licenciatura o superior. (Bureau, s.f.).
De la misma fuente, obtuvimos el ingreso mediano por condado, con un margen de error de cinco años. A diferencia del articulo, nosotros para las poblaciones demograficas, vamos a usar los totales en miles.

Estadísticas descriptivas

Como podemos ver en la figura 1 , hay una relación aparentemente creciente entre el número de decesos por suicidio y el ingreso mediano, a excepción de 2012-2013 donde el número de suciciidios en promedio por condado empieza a decaer, mientras que el ingreso mediano en miles de dolares se mantiene en crecimiento constante, a lo largo del periodo de referencia 2010-2019.

Como podemos ver en la figura 2 , hay una relación aparentemente creciente entre el número de decesos por suicidio y el primedio del porcentaje de graduados universitarios, a excepción de 2014-2015 donde el número de graduados en promedio por condado empieza a decaer.

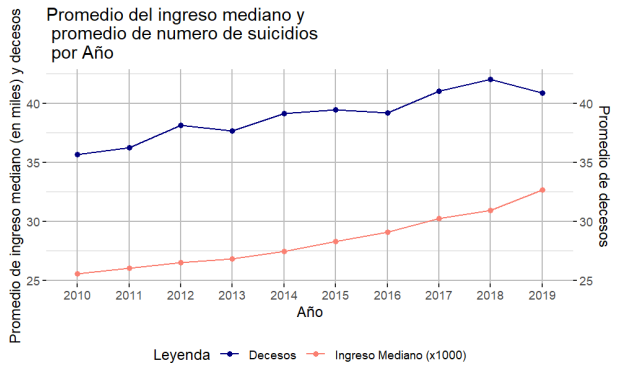


Figura 1: Número Promedio de Suicidios vs. Ingreso Mediano

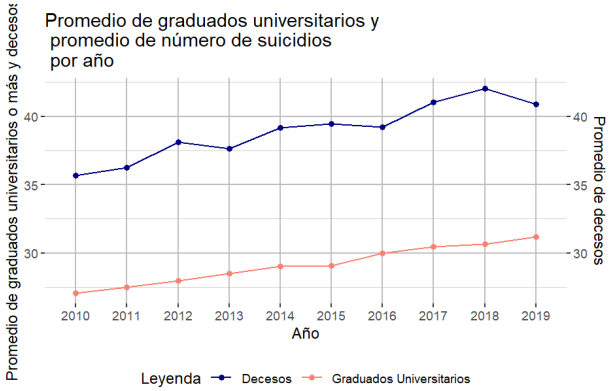


Figura 2: Número Promedio de Suicidios y Número Promedio de Graduados con Título de Licenciatura o Superior

Modelamiento

Sea $\mathbf{Y}_{it}$: *Número de decesos por suicidio en el condado i durante el año t.* Usando `Ecuaciones de Estimación Generalizadas (GEE)`El modelo propuesto inicialmente es:

$$\begin{cases} \log(\mu_{it}) = \mathbf{x}_{it}^{\top}\boldsymbol{\beta} \\ \text{Var}(Y_{ij}) = \phi\, V(\mu_{ij}) \\ \text{Corr}(Y_{ij}, Y_{it}) = r_{ik}(\rho) \end{cases}$$

Se ajustaron distintos modelos y finalmente se escogió el que tiene el siguiente predictor lineal:

$$\begin{aligned} g(\mu_{it}) = \beta_0 + \beta_1 \cdot \log(\text{Med_Income}_{it}) \quad &+ \beta_2 \cdot \text{Pop_Male}_{it} + \beta_3 \cdot \text{Pop_White}_{it} + \beta_4 \cdot \text{Pop_Black_or_AA}_{it} \\ &+ \beta_5 \cdot \text{Pop_AIAN}_{it} + \beta_6 \cdot \text{Pop_Asian}_{it} + \beta_7 \cdot \text{Pop_Hispanic}_{it} + \beta_8 \cdot \log(\text{Pop_College_Educated}_{it}) \\ &+ \beta_9 \cdot \big(\log(\text{Pop_College_Educated}_{it}) \cdot \log(\text{Med_Income}_{it})\big) \end{aligned}$$

Escogiendo la estructura de correlación

Para escoger una estructura de correlación apropiada que se ajuste a los datos, vamos a utilizar el **CIC**: Correlation Information Criterion (Hin and Wang, 2009): Hin y Wang, 2009, que funciona como un criterio de información tradicional para seleccionar modelos en terminos de la verosimilitud, solo que en este caso tenemos en cuenta la estructura de correlación que en modelos bajo el supuesto de independencia no se tiene en cuenta.

El CIC se define como: $\text{CIC} = \text{traza}\left\{n\hat{\phi}^{-1}(X^{\top}\hat{K}\hat{A}^{-1}K\hat{X})\hat{V}ar_R(\hat{\beta})\right\}$

Luego tenemos que el modelo a seleccionar es el modelo con estructura de correlacion estacionaria 1 dependiente como lo dice el CIC en la Figura 1. Así el modelo ajustado seleccionado, estima los parámetros como se ve en la Figura 2:

	Modelo	Correlación	CIC
1	fit8	Independence	250.98
2	fit12	Non-Stationary M-dependent(2)	266.52
3	fit13	Stationary M-dependent(1)	243.25
4	fit14	User-defined	250.98

Cuadro 1: Comparación de modelos GEE según la estructura de correlación y el criterio de información (CIC)

Variable	Estimate	Std. Error	z-value	$Pr(>\|z\|)$
(Intercept)	-17.62147	3.98802	-4.41861	9.9339e-06
log(Med_Income)	2.25184	0.39511	5.69925	1.2033e-08
log(Bachelor's degree or higher)	6.91652	1.11938	6.17890	6.4552e-10
% population Male	-0.07763	0.01074	-7.22609	4.9708e-13
% White	0.00442	0.00036	12.40758	< 2,22e-16
% Black or African American	0.00366	0.00085	4.33313	1.4701e-05
% American Indian and Alaska Native	0.00688	0.00204	3.37589	0.00074
% Asian	0.01442	0.00352	4.09287	4.2606e-05
% Native Hawaiian and Pacific Islander	0.04651	0.01297	3.58559	0.00034
% Hispanic/Latino	0.00000	0.00000	23.77655	< 2,22e-16
log(Med_Income):log(Bachelor's degree)	-0.63881	0.11063	-5.77454	7.7165e-09
Dispersion	16.36417			

Cuadro 2: Estimaciones del modelo seleccionado usando logaritmos del ingreso mediano y nivel educativo

Analisis de residuales

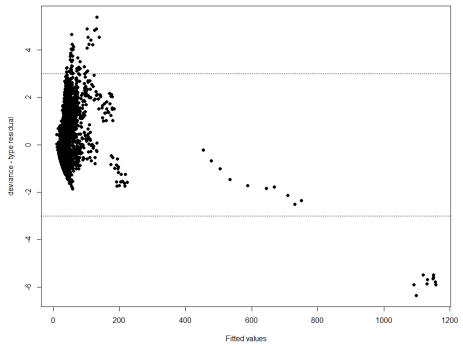


Figura 3: Residuales de Devianza

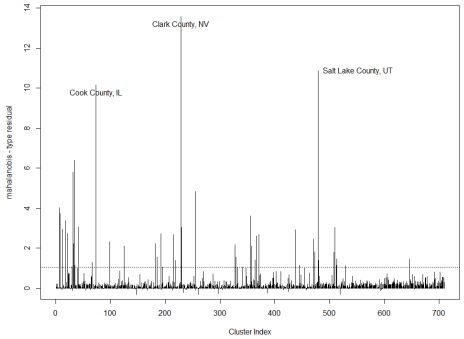


Figura 4: Residuales de Mahalanobis

Como podemos ver el modelo en general ajusta bien a los datos; En los residuales de mahalanobis, en particular podemos verque hay ciertas observaciones cuyos residuos son claramente elevados como lo son el condad Clark en Nevada, el condado Cook en Illinois y Salt Lake en Utah, esto se debe a que en estos condados en particular el modelo subpronostica el promedio de suicidios anual. Sin embargo la variabilidad en general se ve capturada por el modelo intra clusters.

Interpretacion

A través del tiempo, un incremento de $100.000 en el ingreso mediano por hogar está asociado con un aumento del 2 % en la tasa esperada de muertes por suicidio.

A través del tiempo, Un aumento en un individuo graduado universitario en el condado se asocia con un incremento del 2.94 % en la tasa esperada de muertes por suicidio.

A través del tiempo, por cada persona blanca adicional en el condado, lo que representa un incremento del 0.193 % en la tasa de suicidios.

Conclusiones

Los datos muestran que existe una relación entre el ingreso mediano y la tasa de suicidios, aunque dicha asociación no es negativa, sino ligeramente positiva. A pesar de ser un efecto reducido, resulta estadísticamente

significativo. Esto sugiere que las estrategias de prevención del suicidio deberían considerar enfoques dirigidos a los sectores de mayores ingresos.

Asimismo, se evidencia una asociación entre el nivel educativo y el suicidio, con un aumento en la tasa entre personas con educación universitaria. Por tanto, se recomienda implementar programas de prevención específicos en instituciones de educación superior.

Referencias

Bureau, U. C. (s.f.). EDUCATIONAL ATTAINMENT [Accessed on 5 May 2024]. https://data.census.gov/table/ACSST1Y2010.S1501?t=Educational%20Attainment&g=010XX00US$0500000&y=2010

Centers for Disease Control and Prevention. (2024, abril). Facts about suicide [Retrieved April 13, 2022]. *Centers for Disease Control and Prevention*.

Hanley, J. A., Negassa, A., Edwardes, M. D. d., & Forrester, J. E. (2003). Statistical Analysis of Correlated Data Using Generalized Estimating Equations: An Orientation. *American Journal of Epidemiology*, *157*(4), 364-375. https://doi.org/10.1093/aje/kwf215

Hin, L.-Y., & Wang, Y.-G. (2009). Working-correlation-structure identification in generalized estimating equations [[p110]]. *Statistics in Medicine*, *28*(4), 642-658.

Liang, A., & Su, E. (2022, mayo). *Does Money Buy Enough Happiness: Investigating the Relationship Between Income and Suicide Rates* [Honors in Management Undergraduate Research, Spring 5-15-2022]. https://openscholarship.wustl.edu/